Przemysław Musiał *242473*
Marcin Giska *242390*

Rok akademicki *2022/23*
Poniedziałek, 15:45
Prowadzący: dr inż. Krzysztof Lichy

Data oddania: Ocena:

Sztuczna inteligencja i systemy ekspertowe

Zadanie 2: Poprawa lokalizacji UWB przy pomocy sieci neuronowych

1. Cel

Celem części programistycznej było zaprojektowanie i zaimplementowanie sieci neuronowej, która pozwoli na korygowanie błędów uzyskanych z systemu pomiarowego.

2. Opis architektury sieci neuronowej

Do zaimplementowania sieci neuronowej został wykorzystany interfejs Keras z biblioteki TensorFlow.

- Warstwa 1: 64 neurony, funkcja aktywacyjna - ReLU
- Warstwa 2: 32 neurony, funkcja aktywacyjna - ReLU
- Warstwa 3: 16 neurony, funkcja aktywacyjna – ReLU
- Warstwa 4: 8 neurony, funkcja aktywacyjna – ReLU
- Warstwa 5: 2 neurony, funkcja aktywacyjna – Sigmoid

Wagi neuronów:

```
[[ 0.07507    -0.26235402 -0.1638467  -0.1601508   0.48403364 -0.07333209
   0.21995789 -0.0956281   0.2745356   0.24061441 -0.29373372 -0.03077607
  -0.1977357   0.01242744  0.05264459  0.11933134 -0.00287846  0.19915308
   0.3095348   0.38257024 -0.03710815  0.12965171  0.02358457 -0.28553492
  -0.33381432  0.2784158   0.01161292  0.09475357  0.30181593  0.12476623
  -0.17363063 -0.20485881 -0.17686622  0.34103662 -0.07889722 -0.01879697
  -0.18436083 -0.11603399  0.3131766  -0.19976558  0.2679308  -0.29946834
   0.19686161  0.0967225  -0.21379521 -0.25173596  0.1743734   0.2483384
  -0.24663335  0.3174123   0.21197374  0.3404229  -0.2944067  -0.03425765
  -0.32171416  0.31075624 -0.1802159   0.34315053 -0.00928134 -0.2777361
  -0.17197196  0.05470686  0.2836668  -0.16871239]
 [-0.57346004 -0.12161392  0.28223845  0.62589425 -0.40059966 -0.18827164
  -0.50831336 -0.26395556 -0.04879035  0.38234937 -0.20031281  0.33642682
```

0.07226059 -0.32757416 0.35302764 0.37238008 -0.08771144 0.2780216
-0.5044546 0.257925 -0.13625844 0.10850492 0.532528 -0.02261394
0.22942573 -0.40678704 0.00417479 -0.2196061 -0.6922334 -0.49436668
0.03248739 -0.08206646 -0.13025118 0.5889908 -0.08971477 0.3389687
0.05594277 -0.29608253 -0.4489692 0.32792336 -0.03504704 -0.03459731
0.39134958 0.5285083 0.19795412 -0.17327206 0.07658665 -0.10601222
-0.21438894 -0.31970745 0.25158668 0.40115193 0.09562522 -0.18760137
-0.14319159 -0.49833855 0.00227317 0.15590037 -0.24587668 0.02352029
0.47551036 0.00459053 -0.11542412 0.32865402]]

Trenowanie sieci neuronowej zajmowało 150 epok.

3. Opis algorytmu uczenia sieci neuronowej

- Inicjalizacja danych: W pierwszym kroku inicjalizowane są niezbędne biblioteki oraz wczytywane są dane wejściowe z plików Excel.

- Przygotowanie danych: Następnie dane wejściowe są przetwarzane w celu przygotowania ich do uczenia sieci. Proces ten obejmuje usunięcie niektórych kolumn, wypełnienie wartości NaN zerami oraz normalizację wartości danych.

- Podział danych treningowych: Kolejnym krokiem jest podział danych treningowych na dane treningowe oraz dane walidacyjne. Dane treningowe stanowią około 90% zbioru, natomiast dane walidacyjne to pozostałe 10%.

- Utworzenie modelu sieci neuronowej: Algorytm tworzy sekwencyjny model sieci neuronowej przy użyciu biblioteki TensorFlow. Model składa się z warstw gęstych (Dense), gdzie każda warstwa zawiera różną liczbę neuronów oraz funkcję aktywacji.

- Kompilacja modelu: Następnie model sieci neuronowej jest kompilowany, co obejmuje określenie optymalizatora (Adam), funkcji straty (MeanSquaredError) oraz metryk (dokładność).

- Uczenie modelu: Algorytm rozpoczyna proces uczenia modelu na danych treningowych przez określoną liczbę epok. W każdej epoce, dane są podzielone na paczki o określonym rozmiarze (batch_size), a model jest aktualizowany w celu minimalizacji funkcji straty. Model jest również oceniany na danych walidacyjnych w celu monitorowania postępu uczenia.

- Ocena modelu: Po zakończeniu procesu uczenia, model jest oceniany na danych

weryfikacyjnych w celu określenia jego dokładności. Dodatkowo, waga pierwszej warstwy neuronowej jest wypisywana w celu analizy modelu.

- Przetwarzanie danych: Nauczoną sieć można użyć do przewidywania wyników na danych weryfikacyjnych. Wyniki są przekształcane do pierwotnego zakresu danych, aby umożliwić ich interpretację.

- Obliczenie błędu: Na podstawie wyników przewidywanych i prawdziwych danych, obliczany jest błąd pomiarowy, zarówno dla wyników przefiltrowanych, jak i nieprzefiltrowanych.

- Eksport danych: Na koniec wyniki są eksportowane do pliku Excel w celu dalszej analizy. Wyniki zawierają przewidziane wartości, błędy pomiarowe oraz inne informacje, które mogą być istotne dla dalszych działań.

4. Porównanie dystrybuant błędu pomiaru

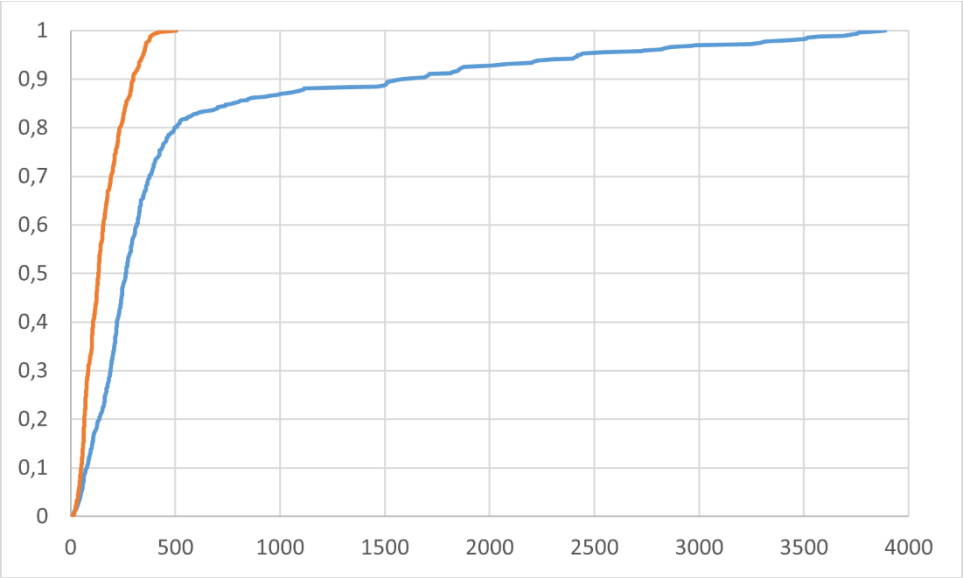

Rys. 1 Dystrybuant błędu pomiaru

Linia o kolorze niebieskim przedstawia dystrybuantę błędu z danych przefiltrowanych.
Linia o kolorze pomarańczowym przedstawia dystrybuantę błędu z danych nieprzefiltrowanych.
Można zauważyć, że występuje poprawa jakości pomiaru, więcej pomiarów ma mniejsze błędy.

5. Kod programu

```
import glob
import os
import pandas as pd
import tensorflow as tf
import numpy as np

columns = [
    'Unnamed: 0',
    'version',
    'alive',
    'tagId',
    'success',
    'timestamp',
    'data__tagData__gyro__x',
    'data__tagData__gyro__y',
    'data__tagData__gyro__z',
    'data__tagData__magnetic__x',
    'data__tagData__magnetic__y',
    'data__tagData__magnetic__z',
    'data__tagData__quaternion__x',
    'data__tagData__quaternion__y',
    'data__tagData__quaternion__z',
    'data__tagData__quaternion__w',
    'data__tagData__linearAcceleration__x',
    'data__tagData__linearAcceleration__y',
    'data__tagData__linearAcceleration__z',
    'data__tagData__pressure',
    'data__tagData__maxLinearAcceleration',
    'data__anchorData',
    'data__acceleration__x',
    'data__acceleration__y',
    'data__acceleration__z',
    'data__orientation__yaw',
    'data__orientation__roll',
    'data__orientation__pitch',
    'data__metrics__latency',
    'data__metrics__rates__update',
    'data__metrics__rates__success',
    'data__coordinates__x',
    'data  coordinates  y',
    'data__coordinates__z',
    'reference__x',
    'reference__y']

if __name__ == '__main__':

    # Odczytanie danych do późniejszego przefiltrowania
    verif_data = pd.read_excel('./dane/pomiary/F10/f10_random_1p.xlsx')
    verif_measured_x = verif_data.pop('data__coordinates__x')
    verif_measured_y = verif_data.pop('data__coordinates__y')
    verif_reference_x = verif_data.pop('reference__x')
    verif_reference_y = verif_data.pop('reference  y')
    verif_measured = pd.concat([verif_measured_x, verif_measured_y], axis=1)
    verif_reference = pd.concat([verif_reference_x, verif_reference_y], axis=1)

    # Odczytanie danych potrzebnych do uczenia sieci neuronowej
    all_files = glob.glob(os.path.join('./dane/pomiary/F10/f10_stat_*.xlsx'))
    df_from_each_file = (pd.read_excel(f, names=columns) for f in all_files)
    concatenated_df = pd.concat(df_from_each_file, ignore_index=True)

    measured_x = concatenated_df.pop('data__coordinates__x')
    measured_y = concatenated_df.pop('data__coordinates__y')
    training_data = pd.concat([measured_x, measured_y], axis=1)

    reference_x = concatenated_df.pop('reference__x')
    reference_y = concatenated_df.pop('reference__y')
    reference_data = pd.concat([reference_x, reference_y], axis=1)

    # Zmiana wszystkich wartosci "nan" na zera
    verif_measured.fillna(0, inplace=True)
    verif_reference.fillna(0, inplace=True)
    training_data.fillna(0, inplace=True)
    reference_data.fillna(0, inplace=True)

    # Dodanie offsetu dla lepszego odczytu
```

```
    training_data = (training_data.astype('float32') + 2000) / 10000
    reference_data = (reference_data.astype('float32') + 2000) / 10000

    # Podzial danych treningowych na dane treningowe oraz walidacyjne
    rowCount = int(len(training_data))
    training_data_1 = training_data[:(9 * (rowCount//10))]
    reference_data_1 = reference_data[:(9 * (rowCount//10))]
    val_data_measured = training_data[(9 * (rowCount//10)):]
    val_data_reference = reference_data[(9 * (rowCount//10)):]
    val_data_measured.reset_index(drop=True, inplace=True)
    val_data_reference.reset_index(drop=True, inplace=True)

    # Dodanie offsetu dla lepszego odczytu
    verif_measured = (verif_measured.astype('float32') + 2000) / 10000
    verif_reference = (verif_reference.astype('float32') + 2000) / 10000

    # Utworzenie sieci
    model = tf.keras.Sequential([
#liczba epok - 150
        tf.keras.layers.Dense(64, activation=tf.nn.relu),                       #I
warstwa ukryta - 64 neurony, funkcja aktywacyjna to ReLU
        tf.keras.layers.Dense(32, activation=tf.nn.relu),                       #II
warstwa ukryta - 32 neurony, funkcja aktywacyjna to ReLU
        tf.keras.layers.Dense(16, activation=tf.nn.relu),                       #III
warstwa ukryta - 16 neuronów, funkcja aktywacyjna to ReLU
        tf.keras.layers.Dense(8, activation=tf.nn.relu),                        #IV
warstwa ukryta - 8 neuronów, funkcja aktywacyjna to ReLU
        tf.keras.layers.Dense(2, activation=tf.nn.sigmoid),
#Warstwa wyjściowa - 2 neurony, funkcja aktywacyjna to funkcja sigmoidalna
    ])

    # Kompilacja sieci przy pomocy optymalizatora "Adam"
    model.compile(optimizer=tf.keras.optimizers.Adam(),
loss=tf.keras.losses.MeanSquaredError(), metrics=['accuracy'])

    # Nauczanie sieci za pomoca danych statycznych
    model.fit(np.asarray(training_data_1), np.asarray(reference_data_1), epochs=150,
batch_size=512,
              validation_data=(val_data_measured, val_data_reference))

    # Wypisanie wag neuronow
    model.evaluate(verif_measured, verif_reference, batch_size=512)
    weights = model.layers[0].get_weights()[0]
    print(weights)

    # Uzycie nauczonej juz sieci w celu przefiltrowania danych
    result = model.predict(verif_measured)
    result = result * 10000 - 2000
    result_df = pd.DataFrame(result)

    # Ulatwienie dostepu do danych poprzez przekazanie ich do list
    result_x_array = []
    result_y_array = []
    for x, y in result:
        result_x_array.append(x)
        result_y_array.append(y)
    reference_x_array = verif_reference_x.to_list()
    reference_y_array = verif_reference_y.to_list()
    measured_x_array = verif_measured_x.to_list()
    measured_y_array = verif_measured_y.to_list()

    # Blad pomiarowy
    error_filtered = []
    error_unfiltered = []
    for i in range(len(result_x_array)):
        buff_filtered = (np.sqrt(np.power(result_x_array[i] - reference_x_array[i], 2)
+ np.power(result_y_array[i] - reference_y_array[i], 2)))
        buff_unfiltered = (np.sqrt(np.power(measured_x_array[i] -
reference_x_array[i], 2) + np.power(measured_y_array[i] - reference_y_array[i], 2)))
        error_filtered.append(buff_filtered)
        error_unfiltered.append(buff_unfiltered)
    result_df['error_filtered'] = error_filtered
    result_df['error_unfiltered'] = error_unfiltered

    # Wyeksportowanie danych do pliku excel
    result_df.to_excel('wynik_F10.xlsx', engine='xlsxwriter')
    print(result)
```